

TP 2 – Formules et nettoyage sous Excel

Nettoyer et enrichir un fichier de commandes

Axel Guérin

M1 DATA

Durée : 2 heures

Fichier de travail :

`seance2_TP_commandes_brutes.xlsx`

Objectif

Transformer un export brut de commandes en un jeu de données **propre, cohérent et exploitable**.

Vous devrez réutiliser les fonctions et méthodes présentées pendant le cours et la démonstration.

Contexte

Vous travaillez comme **Data Analyst** pour une entreprise de distribution multicanale.

Vous recevez un export contenant les commandes réalisées en 2025 et 2026.

Les données proviennent de plusieurs systèmes :

- site Web ;
- magasins ;
- marketplaces ;
- système de gestion des commandes.

Problème

Le fichier n'est pas directement exploitable.

Votre première mission consiste à **contrôler et nettoyer les données**.

Les données disponibles

Le fichier contient notamment :

- identifiant de commande ;
- date de commande ;
- date de livraison ;
- identifiant client ;
- nom du client ;
- email ;
- ville ;
- code postal ;
- canal de vente ;
- produit ;
- catégorie ;
- quantité ;
- prix unitaire ;
- remise ;
- statut ;
- satisfaction.

Avant de commencer

Que représente exactement une ligne du fichier ?

Votre mission

Votre travail devra suivre la démarche suivante :

- ① comprendre les données ;
- ② diagnostiquer les problèmes ;
- ③ structurer le fichier ;
- ④ nettoyer les données textuelles ;
- ⑤ contrôler les types ;
- ⑥ nettoyer et exploiter les dates ;
- ⑦ traiter les valeurs manquantes et les doublons ;
- ⑧ créer de nouvelles variables ;
- ⑨ appliquer des règles métier ;
- ⑩ contrôler le résultat final.

Important

Ne corrigez pas les données au hasard : chaque transformation doit pouvoir être expliquée.

Étape 1 – Explorer les données

Commencez par observer le fichier **sans modifier les données**.

Déterminez :

- le nombre de lignes ;
- le nombre de colonnes ;
- la signification d'une ligne ;
- les principaux types de variables ;
- les colonnes pouvant servir d'identifiants.

Utilisez notamment :

- les filtres ;
- le tri ;
- les valeurs distinctes visibles dans les filtres.

Étape 2 – Diagnostiquer les problèmes

Recherchez les problèmes susceptibles de rendre les analyses incorrectes.

Pensez notamment à contrôler :

- les données textuelles ;
- les formats et types ;
- les dates ;
- les valeurs numériques ;
- les valeurs manquantes ;
- les doublons ;
- les différentes catégories utilisées.

Attention

Certaines anomalies sont évidentes.

D'autres nécessitent d'observer attentivement les valeurs distinctes d'une colonne.

Étape 3 – Construire votre diagnostic

Avant de commencer les corrections, identifiez au minimum **5 problèmes différents** dans le fichier.

Pour chacun, soyez capables d'indiquer :

- ❶ la colonne concernée ;
- ❷ le problème observé ;
- ❸ la conséquence possible ;
- ❹ la correction envisagée.

Exemple de raisonnement

Une même catégorie écrite de plusieurs façons peut créer plusieurs catégories artificielles dans une analyse.

Étape 4 – Structurer les données

Transformez les données en **tableau Excel**.

Nommez votre tableau :

Commandes

Vérifiez :

- les en-têtes ;
- les filtres ;
- la cohérence des colonnes ;
- les types de données.

Pour la suite du TP, privilégiez les **références structurées**.

Étape 5 – Nettoyer les données textuelles

Plusieurs colonnes contiennent des informations textuelles.

Contrôlez notamment :

- Nom_client ;
- Email ;
- Ville ;
- Canal ;
- Categorie ;
- Statut.

Votre objectif est d'obtenir des valeurs :

cohérentes et normalisées

Méthode

Privilégiez des formules reproductibles plutôt que des corrections cellule par cellule.

Quelles fonctions utiliser ?

Vous avez plusieurs outils à votre disposition :

SUPPSPACE()

NOMPROPRE()

MAJUSCULE()

MINUSCULE()

À vous de décider

Toutes les colonnes ne doivent pas nécessairement être normalisées de la même manière.

Étape 6 – Manipuler les chaînes de caractères

Utilisez les fonctions de manipulation de texte pour créer au moins **deux nouvelles informations** à partir des données existantes.

Vous pouvez notamment exploiter :

GAUCHE() DROITE() &

Quelques pistes :

- décomposer un identifiant ;
- créer un nouveau libellé ;
- reconstruire une information à partir de plusieurs colonnes.

Contrainte

Les nouvelles variables doivent avoir une signification claire.

Étape 7 – Contrôler les données numériques

Contrôlez particulièrement :

- Quantité ;
- Prix_unitaire ;
- Remise ;
- Satisfaction.

Posez-vous les questions suivantes :

- Excel reconnaît-il toutes les valeurs comme des nombres ?
- Les formats sont-ils cohérents ?
- Peut-on effectuer des calculs sur toutes les lignes ?

Test

Vos colonnes numériques doivent pouvoir être utilisées correctement dans des calculs et des agrégations.

Étape 8 – Contrôler les dates

Le fichier contient deux dates :

Date_commande

Date_livraison

Vérifiez que les valeurs sont réellement interprétées comme des **dates Excel**.

À partir de Date_commande, créez :

- l'année ;
- le mois ;
- le jour.

Utilisez les fonctions appropriées vues pendant le cours.

Étape 9 – Calculer le délai de livraison

Lorsque les deux dates sont disponibles, calculez :

$$\text{Délai de livraison} = \text{Date de livraison} - \text{Date de commande}$$

Créez une colonne :

Delai_livraison

Réflexion

Que faut-il faire lorsque la date de livraison est absente ?

Une date de livraison manquante représente-t-elle toujours une erreur ?

Étape 10 – Calculer les montants

Créez une colonne :

Montant_brut

avec :

$$\textit{Montant brut} = \textit{Quantité} \times \textit{Prix unitaire}$$

Puis une colonne :

Montant_net

avec :

$$\textit{Montant net} = \textit{Montant brut} \times (1 - \textit{Remise})$$

Utilisez les **références structurées** du tableau.

Étape 11 – Créer une segmentation

Créez une colonne permettant de classer les commandes selon leur **montant net**.

Vous définirez vous-même les seuils.

Par exemple, vous pouvez distinguer :

- petite commande ;
- commande standard ;
- commande importante.

Objectif

Utiliser une ou plusieurs fonctions `SI()` pour transformer une valeur numérique en catégorie métier.

Étape 12 – Construire une règle avec ET

L'entreprise souhaite identifier certaines commandes **prioritaires**.

Construisez une règle utilisant au minimum :

- le montant de la commande ;
- le canal de vente ;
- et/ou son statut.

Votre formule devra utiliser :

SI() + ET()

Important

Définissez et expliquez vous-même votre règle métier.

Étape 13 – Construire une règle avec OU

Créez maintenant une variable permettant d'identifier les commandes nécessitant une attention particulière.

Vous pouvez vous appuyer sur :

- le statut ;
- la satisfaction ;
- le délai de livraison ;
- ou une combinaison de ces informations.

Votre formule devra utiliser :

SI() + OU()

Expliquez la règle choisie.

Étape 14 – Valeurs manquantes

Identifiez les colonnes contenant des valeurs manquantes.

Pour chaque colonne concernée, demandez-vous :

- ❶ Pourquoi cette valeur peut-elle être absente ?
- ❷ Est-ce réellement une anomalie ?
- ❸ Cette ligne reste-t-elle exploitable ?
- ❹ Faut-il conserver, corriger ou exclure l'observation ?

Attention

N'appliquez pas automatiquement la même décision à toutes les valeurs manquantes.

Étape 15 – Rechercher les doublons

Recherchez les éventuels doublons dans le fichier.

Commencez par étudier :

ID_Commande

Puis déterminez si les lignes concernées représentent :

- de véritables doublons ;
- plusieurs événements légitimes ;
- ou une anomalie à examiner.

Avant toute suppression

Justifiez les colonnes utilisées pour définir un doublon.

Étape 16 – Contrôler le résultat

Une fois le nettoyage terminé, effectuez un nouveau contrôle.

Vérifiez notamment :

- les valeurs distinctes des variables catégorielles ;
- les types numériques ;
- les dates ;
- les valeurs manquantes restantes ;
- les doublons ;
- les nouvelles colonnes calculées.

Important

Une formule qui ne produit pas d'erreur Excel ne garantit pas que le résultat est correct.

Étape 17 – Quelques contrôles métier

Utilisez votre fichier nettoyé pour calculer :

- le montant net total ;
- le montant moyen d'une commande ;
- la quantité totale commandée ;
- le délai moyen de livraison ;
- le nombre de commandes par statut.

Ces résultats servent principalement à vérifier que vos données sont désormais exploitables.

Question

Les résultats obtenus vous semblent-ils cohérents ?

Bonus – Pour aller plus loin

Si vous avez terminé :

- ❶ Créez une règle combinant SI, ET et OU.
- ❷ Identifiez les commandes livrées avec un délai particulièrement long.
- ❸ Identifiez les clients ayant laissé une mauvaise satisfaction.
- ❹ Créez une catégorie de remise :
 - aucune ;
 - faible ;
 - moyenne ;
 - importante.
- ❺ Imaginez une nouvelle variable métier utile à l'entreprise.

Votre classeur final doit contenir :

- un tableau Excel nommé `Commandes` ;
- des données textuelles normalisées ;
- des données numériques correctement typées ;
- des dates exploitables ;
- des variables temporelles ;
- un délai de livraison ;
- les montants brut et net ;
- une segmentation des commandes ;
- une règle utilisant ET ;
- une règle utilisant OU ;
- un traitement justifié des valeurs manquantes ;
- un traitement justifié des doublons.

Les fonctions à votre disposition

Texte

- SUPPRESSE
- NOMPROPRE
- MAJUSCULE
- MINUSCULE
- GAUCHE
- DROITE

Logique


- SI
- ET
- OU
- comparaisons

Dates

- ANNEE
- MOIS
- JOUR
- calcul entre dates

Mais...

C'est à vous de déterminer **quelle fonction utiliser et à quel moment.**



À vous de jouer !

2 heures

`seance2_TP_commandes_brutes.xlsx`