

Outils et méthodes d'analyse décisionnelle

Séance 3 – Excel : enrichissement et croisement de données

Axel Guérin

M1 DATA

Objectifs de la séance

À l'issue de cette séance, vous devrez être capables de :

- comprendre pourquoi les données sont souvent réparties dans plusieurs tables ;
- identifier une **clé permettant de croiser des données** ;
- effectuer une **recherche exacte** ;
- utiliser RECHERCHEV ;
- utiliser RECHERCHEX ;
- comprendre leurs différences ;
- effectuer une **recherche approximative** ;
- enrichir automatiquement une table principale.

Objectif général

Passer de plusieurs tables séparées à un jeu de données enrichi et exploitable pour l'analyse.

Les données ne sont pas toujours dans une seule table

Imaginons une table de ventes :

Vente	Client	Produit	Quantité
V001	C014	P003	2
V002	C021	P008	1
V003	C014	P005	3

Elle ne contient pas nécessairement :

- le nom du client ;
- sa région ;
- le nom du produit ;
- sa catégorie ;
- son prix.

Plusieurs tables spécialisées

Les informations peuvent être réparties dans plusieurs tables.

Ventes	Clients	Produits
Date	ID Client	ID Produit
ID Client	Nom	Produit
ID Produit	Ville	Catégorie
Quantité	Région	Prix

Comment récupérer les informations nécessaires dans la table **Ventes** ?

Pourquoi séparer les informations ?

Pourquoi ne pas stocker toutes les informations dans chaque vente ?

Si un client réalise 500 achats :

faut-il répéter son nom, son adresse et sa région 500 fois ?

Séparer les données permet notamment :

- de limiter les répétitions ;
- de réduire les incohérences ;
- de faciliter les mises à jour ;
- de structurer les informations.

Lien avec les bases de données

Cette organisation reprend les principes du **modèle relationnel**.

La clé permet de relier les tables

Pour croiser deux tables, il faut une information commune.

VENTES

Vente	ID Client
V001	C014
V002	C021



CLIENTS

ID Client	Nom	Région
C014	Martin	Ouest
C021	Durand	Nord

Qu'est-ce qu'une bonne clé ?

Une clé utilisée pour retrouver une information doit idéalement être :

- présente dans les deux tables ;
- stable ;
- correctement renseignée ;
- cohérente entre les sources ;
- unique dans la table de référence.

Exemple :

`ID_Client = C014`

À éviter

Utiliser le nom d'une personne ou le nom d'un produit comme identifiant peut être dangereux : doublons, fautes de saisie, changements de nom...

Avant une recherche : contrôler les clés

Supposons :

Ventes	Clients
C014	C014
C021	C021
C037	C037
C052	—

Que se passe-t-il pour C052 ?

Important

Une formule de recherche ne peut pas inventer une information absente de la table de référence.

Recherche exacte

Une **recherche exacte** consiste à rechercher une valeur précise dans une table.

Par exemple :

C014

doit correspondre exactement à :

C014

On peut alors récupérer une information associée :

C014 → Ouest

La fonction RECHERCHEV

RECHERCHEV recherche une valeur dans la **première colonne** d'un tableau.

Syntaxe :

`=RECHERCHEV(valeur; table; no_colonne; correspondance)`

Exemple :

`=RECHERCHEV(A2;Clients!$A$2:$D$100;4;FAUX)`

Cela signifie :

- ① rechercher la valeur de A2 ;
- ② dans la première colonne de la table Clients ;
- ③ retourner la quatrième colonne ;
- ④ demander une correspondance exacte.

RECHERCHEV : correspondance exacte

Pour une recherche exacte :

FAUX

Exemple :

```
=RECHERCHEV([@ID_Client];Clients; 4; FAUX)
```

Bon réflexe

Pour rechercher un identifiant, utilisez généralement une **correspondance exacte**.

Les limites de RECHERCHEV

RECHERCHEV fonctionne, mais possède plusieurs limites.

- La colonne recherchée doit être la première du tableau.
- La recherche se fait uniquement vers la droite.
- Le numéro de colonne est écrit manuellement.
- L'ajout ou la suppression d'une colonne peut modifier le résultat.
- La formule est moins lisible sur de grandes tables.

Conséquence

RECHERCHEV reste très répandue, mais Excel propose aujourd'hui une fonction plus flexible.

La fonction RECHERCHEX

RECHERCHEX sépare :

- la colonne dans laquelle chercher ;
- la colonne contenant le résultat.

Syntaxe simplifiée :

```
=RECHERCHEX(valeur; colonne_recherche; colonne_résultat)
```

Exemple :

```
=RECHERCHEX(A2;Clients[ID_Client];Clients[Region])
```

Résultat :

C014 → Ouest

RECHERCHEX et références structurées

Avec des tableaux Excel :

```
=RECHERCHEX([@ID_Client];Clients[ID_Client];Clients[Region])
```

La formule se lit presque comme une phrase :

Rechercher cet **ID Client**
dans **Clients[ID Client]**
et retourner **Clients[Region]**.

Avantage

Les références structurées rendent la formule plus lisible et plus robuste.

Gérer une valeur absente

Que se passe-t-il si l'identifiant recherché n'existe pas ?

Par défaut, Excel peut renvoyer :

#N/A

Avec RECHERCHEX, on peut prévoir un résultat alternatif :

```
=RECHERCHEX([@ID_Client];Clients[ID_Client];Clients[Region];"Client inconnu")
```

Attention

Masquer une erreur ne corrige pas la donnée.

Il faut comprendre pourquoi la correspondance est absente.

RECHERCHEV ou RECHERCHEX ?

	RECHERCHEV	RECHERCHEX
Recherche exacte	Oui	Oui
Recherche vers la gauche	Non	Oui
Références explicites	Limitées	Oui
Numéro de colonne	Oui	Non
Valeur si absence	Non directement	Oui
Lisibilité	Moyenne	Bonne

Dans ce cours

Vous devez savoir lire et utiliser RECHERCHEV, mais nous privilégierons RECHERCHEX lorsqu'elle est disponible.

Enrichir une table de ventes

Table initiale :

Date	ID Client	ID Produit	Quantité
15/03	C014	P003	2
16/03	C021	P008	1

Après enrichissement :

Date	Client	Région	Produit	Catégorie	Qté
15/03	C014	Ouest	P003	Audio	2
16/03	C021	Nord	P008	Info.	1

Les nouvelles informations proviennent des **tables de référence**.

Une recherche par information

À partir de l'identifiant client :

ID_Client

on peut récupérer :

- le nom ;
- la ville ;
- la région ;
- le segment client.

À partir de l'identifiant produit :

ID_Produit

on peut récupérer :

- le produit ;
- la catégorie ;
- la marque ;
- le prix.

Enrichissement et calcul

Une fois le prix récupéré depuis la table Produits :

$$\text{Montant} = \text{Quantité} \times \text{Prix}$$

La table initiale :

ID Produit + Quantité

devient :

Produit + Catégorie + Prix + Quantité + Montant

Principe

Une recherche permet de récupérer une information.

Cette information peut ensuite servir à créer de nouveaux indicateurs.

Recherche exacte ou approximative ?

Toutes les recherches ne cherchent pas nécessairement une valeur identique.

Recherche exacte :

C014 → Martin

Recherche approximative :

Montant = 750 € → Remise = 5%

Le montant 750 n'est pas nécessairement présent dans la table des tarifs.

Exemple de grille tarifaire

Supposons la table suivante :

Montant minimum	Remise
0	0%
500	5%
1000	10%
2000	15%

Pour une commande de :

750 €

la remise applicable est :

5%

Principe de la recherche approximative

Pour une valeur de 750 €, Excel doit retrouver le seuil :

500 €

car :

$$500 \leq 750 < 1000$$

On associe alors :

$$750 \rightarrow 5\%$$

Attention

Une recherche approximative nécessite de bien comprendre la structure et l'ordre des seuils.

RECHERCHEV approximative

Avec RECHERCHEV, le dernier argument permet de choisir le type de correspondance.

Recherche exacte :

FAUX

Recherche approximative :

VRAI

Exemple :

=RECHERCHEV(A2;Tarifs; 2; VRAI)

Important

Pour une recherche approximative avec RECHERCHEV, la première colonne doit être

Recherche approximative avec RECHERCHEX

RECHERCHEX permet également de contrôler le mode de correspondance.

Syntaxe complète :

```
=RECHERCHEX(valeur; recherche; résultat; si_absent; mode)
```

Parmi les modes :

- 0 : correspondance exacte ;
- -1 : exacte ou valeur immédiatement inférieure ;
- 1 : exacte ou valeur immédiatement supérieure.

Pour une grille de seuils, le choix dépend de la logique métier utilisée.

Un autre exemple : frais de livraison

Poids minimum	Tarif
0 kg	4,90 €
2 kg	6,90 €
5 kg	9,90 €
10 kg	14,90 €

Pour un colis de :

7,2 kg

on cherche le seuil correspondant.

Applications

Tarifs, remises, commissions, catégories d'âge, niveaux de risque, tranches de prix...

Avant d'effectuer une recherche :

- ① identifier la table principale ;
- ② identifier la table de référence ;
- ③ identifier la clé commune ;
- ④ vérifier la qualité des clés ;
- ⑤ vérifier l'unicité dans la table de référence ;
- ⑥ choisir recherche exacte ou approximative ;
- ⑦ contrôler les résultats.

Réflexe

Ne commencez pas par écrire la formule.

Commencez par comprendre **quelle relation relie les données.**

Attention aux doublons dans la table de référence

Supposons :

ID Client	Région
C014	Ouest
C021	Nord
C014	Sud

Quelle région doit être retournée pour C014 ?

Problème

Une clé censée identifier une ligne de référence doit être **unique**.

Attention aux types

Ces deux valeurs semblent identiques :

00125 00125

Mais l'une peut être du texte et l'autre un nombre.


Autres problèmes fréquents :

- espaces parasites ;
- casse incohérente ;
- zéros initiaux supprimés ;
- identifiants manquants.

Lien avec la séance précédente

Le nettoyage des données est indispensable avant de croiser des tables.

- ① Les données sont souvent réparties dans plusieurs tables.
- ② Une **clé commune** permet de relier ces tables.
- ③ La recherche **exacte** est adaptée aux identifiants.
- ④ RECHERCHEV est historique et encore très utilisée.
- ⑤ RECHERCHEX est plus flexible et généralement plus lisible.
- ⑥ Une recherche **approximative** permet de travailler avec des seuils et des tranches.
- ⑦ Les tables doivent être contrôlées avant tout croisement.



Place à la démonstration

Ventes + Clients + Produits + Tarifs

Croiser plusieurs tables pour construire un jeu de données enrichi.