

# TP 3 – Enrichissement et croisement de données

## Analyse de l'activité et de la performance des salariés

Axel Guérin

M1 DATA

**Durée : 2 heures**

Fichier de travail :

`seance3_TP_activite_salaries.xlsx`

## Objectif

Croiser plusieurs tables afin de construire un jeu de données **enrichi et exploitable**.

Vous devrez réutiliser les méthodes présentées pendant le cours et la démonstration.

# Contexte

Vous travaillez comme **Data Analyst** au sein d'une entreprise présente sur plusieurs sites en France.

La direction souhaite analyser :

- l'activité des salariés ;
- leur performance ;
- la répartition des collaborateurs ;
- les postes occupés ;
- les primes associées aux performances.

## Problème

Les informations nécessaires sont réparties dans plusieurs tables.  
La table d'activité seule ne permet pas de réaliser l'analyse.

# Les données disponibles

Le classeur contient quatre tables de données.

## Activite

500 relevés mensuels

- salarié ;
- mois ;
- performance ;
- heures projet.

## Employes

30 salariés

Identité, localisation, poste et date d'embauche.

## Postes

8 postes

Intitulé, service, niveau et salaire de référence.

## Primes

6 seuils

Grille permettant de déterminer le taux de prime selon la performance.

# Votre mission

Vous devez enrichir la table `Activite` afin d'obtenir un fichier permettant d'analyser les performances des salariés.

Vous devrez notamment :

- ① comprendre la structure des données ;
- ② identifier les relations entre les tables ;
- ③ structurer les différentes tables ;
- ④ récupérer les informations relatives aux salariés ;
- ⑤ récupérer les informations relatives aux postes ;
- ⑥ gérer les correspondances absentes ;
- ⑦ déterminer le taux de prime ;
- ⑧ calculer de nouveaux indicateurs ;
- ⑨ contrôler le résultat final.

# Étape 1 – Explorer le classeur

Commencez par explorer les quatre feuilles :

Activite

Employes

Postes

Primes

Pour chacune, déterminez :

- ce que représente une ligne ;
- l'information principale contenue dans la table ;
- la ou les colonnes pouvant servir de clé.

## Étape 2 – Identifier les relations

Avant d'écrire la moindre formule, représentez mentalement les relations entre les tables.

Complétez la logique suivante :

Activite



???



Employes



???



Postes

## Étape 3 – Identifier les clés

Pour chaque relation, identifiez :

- la clé présente dans la table principale ;
- la clé correspondante dans la table de référence ;
- les informations que cette relation permettra de récupérer.

Vérifiez également :

- que les clés semblent cohérentes ;
- qu'elles sont uniques dans les tables de référence ;
- que leur format est compatible.

### Important

Une recherche correcte commence par une relation correctement identifiée.

## Étape 4 – Transformer les plages en tableaux

Transformez les quatre plages en **tableaux Excel**.

Utilisez les noms suivants :

| Feuille  | Nom du tableau |
|----------|----------------|
| Activite | Activite       |
| Employes | Employes       |
| Postes   | Postes         |
| Primes   | Primes         |

Pour la suite

Utilisez autant que possible les **références structurées**.

## Étape 5 – Enrichir avec les salariés

La table `Activite` contient uniquement :

`ID_Employe`

À partir de la table `Employes`, ajoutez à `Activite` :

- le prénom ;
- le nom ;
- le site ;
- la région ;
- l'identifiant du poste ;
- la date d'embauche.

Utilisez des **recherches exactes**.

# RECHERCHEV et RECHERCHEX

Pour ce premier enrichissement :

- 1 réalisez au moins une recherche avec RECHERCHEV ;
- 2 réalisez les autres recherches avec RECHERCHEX.

Comparez les deux méthodes.

## Questions

Quelle formule est la plus facile à lire ?

Laquelle dépend du numéro de la colonne retournée ?

Laquelle vous semble la plus robuste ?

Avant de continuer, contrôlez plusieurs lignes manuellement.

Pour quelques ID\_Employe :

- ① relevez l'identifiant dans `Activite` ;
- ② retrouvez-le manuellement dans `Employes` ;
- ③ comparez les informations ;
- ④ vérifiez le résultat de vos formules.

## À retenir

Une formule qui s'exécute sans erreur n'est pas nécessairement correcte.

## Étape 6 – Retrouver les informations du poste

Vous disposez maintenant de :

ID\_Poste

dans la table Activite.

Utilisez la table Postes pour récupérer :


- l'intitulé du poste ;
- le service ;
- le niveau ;
- le salaire de référence.

### Objectif

Réaliser un second croisement à partir d'une information obtenue lors du premier croisement.

# Une chaîne d'enrichissement

Votre table suit maintenant une chaîne de relations :



## Étape 7 – Certaines recherches échouent

Lors de vos recherches, vous devriez rencontrer quelques situations particulières.

Certaines lignes peuvent retourner :

#N/A

### Travail demandé

Identifiez la cause de ces erreurs.

Ne les masquez pas immédiatement.

Recherchez les identifiants concernés dans la table de référence.

## Étape 8 – Gérer les correspondances absentes

Une fois la cause identifiée, adaptez vos recherches pour afficher une information compréhensible lorsqu'un salarié n'est pas trouvé.

Par exemple :

Employé inconnu

### Attention

Remplacer #N/A par un texte ne corrige pas le problème.


Vous devez être capables d'expliquer pourquoi la correspondance n'existe pas.

## Étape 9 – Comprendre la grille de primes

Observez la table Primes.

Elle associe un taux de prime à un **score minimum de performance**.

Exemple de logique :



### Question

## Étape 10 – Déterminer le taux de prime

Ajoutez à Activite une colonne :

Taux\_prime

Le taux doit être déterminé à partir :

- du Score\_performance ;
- de la table Primes.

Utilisez une **recherche approximative**.

### Contrôle

Testez manuellement plusieurs scores proches des seuils.

Par exemple : 59, 60, 69, 70, 89, 90, 94, 95.

## Deux méthodes possibles

Effectuez la recherche approximative :

- ① une première fois avec RECHERCHEV ;
- ② puis avec RECHERCHEX.

Comparez les résultats.

### À vérifier

Les deux méthodes doivent retourner le même taux de prime pour un même score.

Conservez ensuite la formule qui vous paraît la plus adaptée.

## Étape 11 – Calculer la prime annuelle théorique

Vous disposez maintenant :

- du salaire de référence ;
- du taux de prime.

Créez une colonne :

Prime\_theorique

avec :

$$\text{Prime théorique} = \text{Salaire de référence} \times \text{Taux de prime}$$

Utilisez une formule avec des **références structurées**.

## Étape 12 – Créer un indicateur de performance

À partir du `Score_performance`, créez une nouvelle variable catégorielle.

Par exemple :

- performance insuffisante ;
- performance correcte ;
- bonne performance ;
- excellente performance.

À vous de décider

Définissez des seuils cohérents.

Vous pouvez réutiliser les fonctions logiques étudiées lors de la séance précédente.

## Étape 13 – Calculer l'ancienneté

Vous avez récupéré la date d'embauche de chaque salarié.

Créez une variable permettant d'obtenir son **ancienneté approximative en années** au moment du relevé.

Vous disposez :

- du mois du relevé ;
- de la date d'embauche.

### Réflexion

Quelle opération ou quelles fonctions peuvent permettre d'obtenir cette information ?

## Étape 14 – Contrôler le résultat final

Votre table `Activite` doit maintenant être beaucoup plus riche.

Contrôlez :

- les informations relatives aux salariés ;
- les informations relatives aux postes ;
- les correspondances absentes ;
- les taux de prime ;
- les primes théoriques ;
- les indicateurs calculés.

Effectuez plusieurs contrôles manuels sur des lignes choisies au hasard.

# À quoi doit ressembler la table finale ?

Elle doit notamment contenir :

- ID activité ;
- mois ;
- ID employé ;
- prénom ;
- nom ;
- site ;
- région ;
- date d'embauche ;
- ancienneté ;
- ID poste ;
- intitulé ;
- service ;
- niveau ;
- salaire de référence ;
- score ;
- taux de prime ;
- prime théorique ;
- heures projet.

## Étape 15 – Exploiter les données enrichies

Répondez aux questions suivantes à partir de votre table finale :

- ① Quel salarié possède le score de performance le plus élevé ?
- ② Quel est le score moyen de performance ?
- ③ Quel est le montant moyen des primes théoriques ?
- ④ Combien d'activités concernent chaque région ?
- ⑤ Quel service possède le plus grand nombre de relevés ?
- ⑥ Quel niveau de poste possède le score moyen le plus élevé ?

Utilisez les outils Excel que vous connaissez déjà.

## Étape 16 – Produire des observations

À partir des données enrichies, formulez au minimum :

# 5 observations

Chaque observation doit :

- être basée sur les données ;
- contenir au moins une valeur chiffrée ;
- être formulée clairement ;
- présenter un intérêt pour l'entreprise.

### Exemple de forme

“Le score moyen des salariés du service X est de ...”


## Bonus – Pour aller plus loin

Si vous avez terminé :

- ➊ Identifiez les salariés apparaissant le plus souvent dans la table d'activité.
- ➋ Comparez la performance moyenne entre les différents sites.
- ➌ Comparez les performances selon le niveau du poste.
- ➍ Calculez la masse totale des primes théoriques.
- ➎ Comparez la performance moyenne selon l'ancienneté.
- ➏ Créez un indicateur combinant performance et nombre d'heures projet.

Votre classeur final doit contenir :

- les quatre plages transformées en tableaux Excel ;
- les informations salariés ajoutées à `Activite` ;
- les informations postes ajoutées à `Activite` ;
- au moins une utilisation de `RECHERCHEV` ;
- plusieurs utilisations de `RECHERCHEX` ;
- une gestion des correspondances absentes ;
- une recherche approximative ;
- le taux de prime ;
- la prime théorique ;
- un indicateur de performance ;
- l'ancienneté ;
- au moins cinq observations sur les données.



# À vous de jouer !

2 heures

`seance3_TP_activite_salaries.xlsx`