Outils et méthodes d'analyse décisionnelle

Séance 6 – Power Query et préparation des données

Axel Guérin

M1 DATA

Objectifs de la séance

À l'issue de cette séance, vous devrez être capables de :

- comprendre les principes d'un processus ETL ;
- expliquer le fonctionnement de Power Query ;
- importer différentes sources de données ;
- appliquer des transformations ;
- gérer les types et les valeurs manquantes ;
- combiner plusieurs tables ;
- fusionner des requêtes ;
- dépivoter des colonnes ;
- construire un pipeline reproductible ;
- actualiser automatiquement les transformations.

Le problème des traitements manuels

Imaginons une entreprise recevant chaque mois un fichier de ventes.

Chaque fichier nécessite :

- la suppression de colonnes inutiles ;
- la correction des types ;
- la suppression des lignes vides ;
- la normalisation de certaines valeurs ;
- l'ajout d'informations complémentaires ;
- la préparation d'une table exploitable.

Problème

Faut-il refaire toutes ces manipulations manuellement chaque mois ?

Une approche reproductible

Au lieu de répéter les manipulations :

Définir les transformations une fois

↓

Enregistrer les étapes

↓

Actualiser avec de nouvelles données

Principe

On automatise la préparation des données en conservant les règles de transformation.

Qu'est-ce que Power Query ?

Power Query est un outil de connexion et de transformation de données.

Il est intégré notamment à :

- Microsoft Excel ;
- Microsoft Power BI.

Il permet de :

- importer des données ;
- nettoyer les données ;
- transformer leur structure ;
- combiner plusieurs sources ;
- automatiser leur préparation.

Qu'est-ce qu'un ETL ?

ETL signifie :

Extract

↓

Transform

↓

Load

Étape 1 – Extract

L'extraction consiste à récupérer des données depuis une ou plusieurs sources.

Exemples :

- fichiers CSV ;
- fichiers Excel ;
- bases de données ;
- dossiers contenant plusieurs fichiers ;
- services web ;
- autres sources compatibles.

Objectif

Accéder aux données nécessaires à l'analyse.

Étape 2 – Transform

La transformation consiste à préparer les données pour leur exploitation.

Exemples :

- changer les types ;
- supprimer des colonnes ;
- filtrer des lignes ;
- corriger des valeurs ;
- créer des colonnes ;
- fusionner des tables ;
- réorganiser les données.

Objectif

Produire des données cohérentes et structurées.

Étape 3 – Load

Le chargement consiste à rendre les données transformées disponibles.

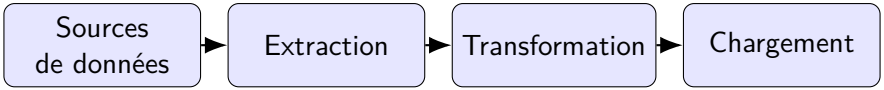
Dans Excel, on peut notamment charger :

- dans une feuille Excel ;
- dans le modèle de données ;
- uniquement comme connexion.

Objectif

Rendre les données prêtes pour l'analyse, les TCD et les dashboards.

ETL et analyse décisionnelle



↓

TCD – Dashboard – Analyse

À retenir

La préparation des données est une étape essentielle avant leur visualisation.

Accéder à Power Query dans Excel

Dans Excel :

Données

↓

Obtenir des données

Les commandes disponibles permettent de sélectionner une source et d'ouvrir l'éditeur Power Query.

L'éditeur Power Query

L'éditeur est organisé autour de plusieurs zones.

- **Requêtes** : liste des requêtes disponibles ;
- **Aperçu** : visualisation des données ;
- **Ruban** : outils de transformation ;
- **Étapes appliquées** : historique des opérations ;
- **Barre de formule** : expression de l'étape sélectionnée.

Point essentiel

Chaque transformation peut être enregistrée comme une étape de la requête.

Les étapes appliquées

Exemple de pipeline :

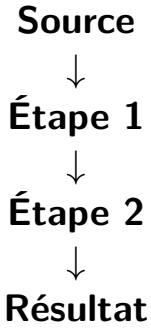
1. Source ;
2. En-têtes promus ;
3. Type modifié ;
4. Colonnes supprimées ;
5. Lignes filtrées ;
6. Colonne calculée ajoutée ;
7. Requêtes fusionnées.

Avantage

Les étapes sont conservées et peuvent être rejouées lors d'une actualisation.

Power Query et les données sources

Power Query applique des transformations à partir d'une source.



Important

Les transformations ne modifient généralement pas directement les fichiers sources.

Importer un fichier CSV

Un fichier CSV contient des données tabulaires séparées par un délimiteur.

Exemples de séparateurs :

- virgule ;
- point-virgule ;
- tabulation.

Lors de l'importation, il faut vérifier :

- le séparateur ;
- l'encodage ;
- les en-têtes ;
- les types détectés.

Importer un fichier Excel

Power Query peut importer :

- des feuilles ;
- des tableaux Excel ;
- des plages nommées compatibles.

Lors de l'importation :

1. sélectionner le fichier ;
2. choisir l'objet à importer ;
3. vérifier l'aperçu ;
4. ouvrir l'éditeur ;
5. appliquer les transformations.

Importer plusieurs fichiers d'un dossier

Une entreprise peut recevoir :

```
ventes_janvier.csv
ventes_fevrier.csv
ventes_mars.csv
ventes_avril.csv
```

Power Query permet de combiner des fichiers provenant d'un même dossier.

Intérêt

Consolider automatiquement plusieurs périodes sans copier-coller les données.

Conditions pour combiner des fichiers

Pour faciliter la combinaison, les fichiers doivent présenter une structure compatible.

Par exemple :

- mêmes colonnes ;
- mêmes significations ;
- mêmes conventions de format ;
- types compatibles.

Attention

Un nouveau fichier ayant une structure différente peut provoquer des erreurs lors de l'actualisation.

Les types de données

Power Query distingue notamment :

- texte ;
- nombre entier ;
- nombre décimal ;
- date ;
- date et heure ;
- booléen.

Exemple

Une date importée comme texte ne peut pas être exploitée correctement comme une date.

Modifier les types

Exemple de données importées :

Date	Quantité	Prix
01/03/2026	3	49,90
02/03/2026	2	29,90
03/03/2026	5	19,90

Il faut vérifier que :

- Date est reconnue comme une date ;
- Quantité est un nombre entier ;
- Prix est un nombre décimal.

Supprimer des colonnes

Une source peut contenir des informations inutiles.

Exemple :

- ID ;
- Date ;
- Produit ;
- Quantité ;
- Prix ;
- Commentaire interne ;
- Ancien code.

Power Query permet de :

- supprimer des colonnes ;
- conserver uniquement certaines colonnes.

Filtrer des lignes

Les filtres permettent de conserver uniquement certaines observations.

Exemples :

- conserver les ventes valides ;
- supprimer les lignes vides ;
- exclure certains statuts ;
- sélectionner une période ;
- exclure des valeurs aberrantes identifiées.

Principe

Le filtre devient une étape enregistrée et sera réappliqué à l'actualisation.

Gérer les valeurs manquantes

Les données peuvent contenir :

- des valeurs nulles ;
- des chaînes vides ;
- des valeurs non renseignées ;
- des erreurs de conversion.

Plusieurs stratégies sont possibles :

- supprimer certaines lignes ;
- remplacer les valeurs ;
- conserver les valeurs nulles ;
- créer un indicateur de donnée manquante.

Le choix dépend du contexte métier.

Transformer les colonnes texte

Power Query propose notamment :

- supprimer les espaces inutiles ;
- nettoyer certains caractères ;
- convertir en majuscules ;
- convertir en minuscules ;
- remplacer des valeurs ;
- fractionner une colonne ;
- fusionner des colonnes.

Exemple

Normaliser les noms de catégories avant de réaliser des regroupements.

Créer une colonne calculée

Power Query permet de créer de nouvelles colonnes à partir des données existantes.

Exemple :

$$\text{Montant} = \text{Quantité} \times \text{Prix unitaire}$$

La formule devient une étape de la transformation.

Avantage

Le calcul est automatiquement réappliqué aux nouvelles lignes lors de l'actualisation.

Deux opérations différentes

Power Query permet de combiner plusieurs tables de deux façons principales.

Ajouter des requêtes

Empiler les lignes de plusieurs tables.

Fusionner des requêtes

Rapprocher les colonnes de plusieurs tables à partir d'une correspondance.

Ajouter $\neq$ Fusionner

Ajouter des requêtes

Imaginons deux tables :

Janvier

Produit	CA
A	100
B	200

Février

Produit	CA
A	150
C	300

Après ajout :

Une seule table contenant les quatre lignes

Fusionner des requêtes

Imaginons deux tables :

Ventes

ID_Produit	Quantité
P01	3
P02	2

Produits

ID_Produit	Catégorie
P01	Audio
P02	Informatique

Après fusion :

ID_Produit	Quantité	Catégorie
P01	3	Audio
P02	2	Informatique

La notion de clé

Pour fusionner deux tables, il faut identifier un champ commun.

Exemple :

`ID_Produit`

La clé permet de retrouver les informations correspondantes.

Attention

Si plusieurs lignes correspondent à une même clé, la fusion peut multiplier les lignes du résultat.

Les types de jointures

Power Query propose plusieurs types de jointures.

Par exemple :

- gauche externe ;
- droite externe ;
- interne ;
- externe complète ;
- gauche anti ;
- droite anti.

Cas fréquent

Une jointure gauche permet de conserver toutes les lignes de la table principale et d'ajouter les correspondances disponibles.

Fusionner : les points de vigilance

Avant une fusion :

1. identifier les clés ;
2. vérifier leurs types ;
3. vérifier leur format ;
4. contrôler les doublons ;
5. choisir la jointure ;
6. contrôler le nombre de lignes obtenu.

Important

Une fusion réussie techniquement n'est pas nécessairement correcte analytiquement.

Qu'est-ce que le dépivotage ?

Le dépivotage consiste à transformer plusieurs colonnes en lignes.

Il est particulièrement utile lorsque des valeurs de dimensions sont utilisées comme noms de colonnes.

Exemple

Un fichier contient une colonne par mois, alors que l'on souhaite disposer d'une colonne Mois et d'une colonne CA.

Avant le dépivotage

Produit	Janvier	Février	Mars
A	100	120	150
B	200	180	210

Les mois sont actuellement représentés par des colonnes.

Cette structure peut être peu pratique pour certaines analyses temporelles.

Après le dépivotage

Produit	Mois	CA
A	Janvier	100
A	Février	120
A	Mars	150
B	Janvier	200
B	Février	180
B	Mars	210

On obtient une structure plus adaptée aux regroupements et aux visualisations.

Principe

Les noms des anciennes colonnes deviennent des valeurs d'une dimension.

Pourquoi dépivoter ?

Le dépivotage permet notamment de :

- normaliser la structure d'un tableau ;
- faciliter les regroupements ;
- simplifier les analyses temporelles ;
- éviter une colonne par période ;
- faciliter la création de TCD ;
- préparer les données pour Power BI.

À retenir

Une structure pratique pour la saisie n'est pas toujours une structure adaptée à l'analyse.

Power Query et le langage M

Les transformations Power Query reposent sur un langage appelé :

M

L'interface graphique permet de générer automatiquement une grande partie du code M.

Conséquence

Il n'est pas nécessaire de programmer pour réaliser de nombreuses transformations.

Exemple de code M

```
let
Source = Excel.CurrentWorkbook()
{[Name="Ventes"]}[Content],

Types = Table.TransformColumnTypes(
Source,
{
 {"Quantite", Int64.Type},
 {"Prix", type number}
}
),
```

Exemple de code M

```
Montant = Table.AddColumn(
Types,
"Montant",
each [Quantite] * [Prix],
type number
)
in
Montant
```

Comprendre la structure du langage M

Le code M utilise fréquemment :

```
let
Etape1 = ...
Etape2 = ...
in
Etape2
```

Principe

Chaque étape peut utiliser le résultat d'une étape précédente.

Le principe d'actualisation

Une fois les transformations définies :

Nouvelles données

↓

Actualisation

↓

Réexécution des transformations

↓

Résultat mis à jour

Exemple : un nouveau fichier mensuel

Un dossier contient initialement :

- ventes_janvier.csv ;
- ventes_fevrier.csv ;
- ventes_mars.csv.

Un nouveau fichier arrive :

`ventes_avril.csv`

Si la requête combine correctement les fichiers du dossier, une actualisation permet d'intégrer ce nouveau fichier.

Les limites de l'automatisation

Un pipeline peut rencontrer des problèmes :

- fichier déplacé ;
- colonne renommée ;
- type de données modifié ;
- valeur inattendue ;
- clé absente ;
- structure de fichier différente.

Important

Reproductible ne signifie pas infaillible.
Un pipeline doit être contrôlé.

Organiser ses requêtes

Quelques bonnes pratiques :

- donner des noms explicites aux requêtes ;
- renommer les étapes importantes ;
- supprimer les étapes inutiles ;
- éviter les transformations redondantes ;
- vérifier les types ;
- contrôler les résultats intermédiaires ;
- distinguer les requêtes sources et finales.

Objectif

Construire un pipeline compréhensible et facile à maintenir.

Contrôler la qualité des données

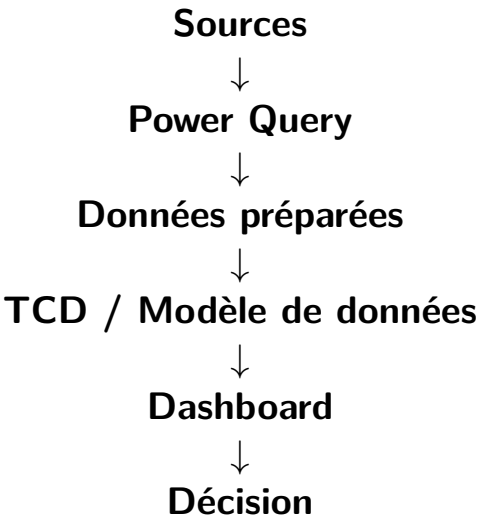
Après les transformations, vérifier :

- le nombre de lignes ;
- le nombre de colonnes ;
- les types ;
- les valeurs nulles ;
- les erreurs ;
- les doublons ;
- les clés de correspondance ;
- les agrégats de contrôle.

Principe

Une transformation correcte doit produire un résultat vérifiable.

Power Query dans une chaîne BI



À retenir

1. Power Query permet de préparer des données.
2. Il repose sur une logique ETL.
3. Les transformations sont enregistrées en étapes.
4. Les sources peuvent être variées.
5. Les requêtes peuvent être ajoutées ou fusionnées.
6. Le dépivotage permet de restructurer des tableaux.
7. Les transformations reposent sur le langage M.
8. L'actualisation permet de rejouer le pipeline.
9. Les résultats doivent toujours être contrôlés.

De la manipulation à l'automatisation

Avant

Manipulations manuelles répétées

⇓

Avec Power Query

Transformations définies une fois

et réexécutées à l'actualisation

Construire un pipeline Power Query

Importer – Transformer – Fusionner – Dépivoter

Puis actualiser les données