TP 6 – Power Query

Construire un pipeline ETL automatisé

Axel Guérin

M1 DATA

Organisation du TP

Durée : 2 heures

Archive de travail :

`seance6_TP_Power_Query_dataset.zip`

Objectif

Construire un pipeline Power Query permettant de préparer automatiquement les données commerciales d'une entreprise.

Le pipeline devra être réutilisable lors de l'arrivée de nouvelles données.

Compétences mobilisées

Vous devrez être capables de :

- importer plusieurs fichiers CSV ;
- combiner des fichiers provenant d'un dossier ;
- corriger les types de données ;
- traiter les valeurs manquantes ;
- identifier les doublons ;
- fusionner plusieurs tables ;
- créer des colonnes calculées ;
- dépivoter des colonnes ;
- charger les données transformées ;
- actualiser automatiquement les requêtes.

Contexte professionnel

Vous travaillez comme **Data Analyst** dans une entreprise commerciale.

Chaque mois, l'entreprise reçoit un fichier CSV contenant les ventes réalisées.

Elle dispose également :

- d'un référentiel produits ;
- d'un référentiel clients ;
- d'objectifs commerciaux par région et par mois.

La direction souhaite automatiser la préparation de ces données.

Le problème actuel

Jusqu'à présent, les données sont préparées manuellement dans Excel.

Chaque mois, il faut :

1. ouvrir le nouveau CSV ;
2. corriger les données ;
3. copier les lignes ;
4. ajouter les informations produits ;
5. ajouter les informations clients ;
6. recalculer les montants ;
7. actualiser les analyses.

Problème

Ces opérations sont répétitives et peuvent générer des erreurs.

Votre mission

Construire un pipeline permettant de passer de :

Fichiers sources

↓

Power Query

↓

Données nettoyées et enrichies

↓

Table exploitable dans Excel

Le processus devra être reproductible.

Étape 1 – Préparer les fichiers

Décompressez l'archive.

Vous disposez notamment :

- de six CSV mensuels ;
- d'un classeur de référentiels ;
- d'un classeur d'objectifs ;
- d'un CSV supplémentaire pour juillet.

Attention

Ne placez pas immédiatement le fichier de juillet dans le dossier des six premiers mois.

Étape 2 – Explorer les sources

Avant d'utiliser Power Query :

1. ouvrez un fichier CSV ;
2. identifiez les colonnes ;
3. observez les formats ;
4. repérez les anomalies potentielles ;
5. examinez les référentiels ;
6. observez la structure des objectifs.

Question

Quelles transformations seront nécessaires pour produire une table exploitable ?

Étape 3 – Identifier les relations

Les données proviennent de plusieurs sources.

Vous devez identifier :

- la clé permettant de retrouver un produit ;
- la clé permettant de retrouver un client ;
- les informations à récupérer ;
- les éventuelles correspondances manquantes.

Question

Pourquoi est-il préférable d'utiliser des identifiants plutôt que des noms pour réaliser une fusion ?

Étape 4 – Importer les ventes

Dans Excel :

Données

↓

Obtenir des données

↓

À partir d'un dossier

Sélectionnez le dossier contenant les six CSV mensuels.

Ouvrez les données dans Power Query.

Étape 5 – Combiner les fichiers

Combinez les six CSV dans une seule requête.

Votre résultat doit contenir :

955 lignes

avant les éventuelles suppressions de lignes incorrectes.

Contrôle

Vérifiez que les six fichiers ont bien été intégrés.

Étape 6 – Vérifier les types

Contrôlez les types de données.

Identifiez notamment :

- les dates ;
- les identifiants ;
- les quantités ;
- les prix ;
- les remises ;
- les valeurs textuelles.

Attention

Une colonne contenant des nombres peut avoir été importée comme texte.

Étape 7 – Corriger les formats

Certaines valeurs numériques utilisent les conventions françaises.

Exemples :

`49,90`

`125,50`

Consigne

Assurez-vous que les colonnes numériques sont correctement reconnues.
Utilisez les paramètres régionaux si nécessaire.

Étape 8 – Identifier les anomalies

Explorez les données.

Recherchez :

- les valeurs manquantes ;
- les dates invalides ;
- les erreurs de conversion ;
- les quantités incohérentes ;
- les identifiants incomplets ;
- les doublons.

Important

Une anomalie doit être comprise avant d'être supprimée ou corrigée.

Étape 9 – Gérer les valeurs manquantes

Choisissez une stratégie cohérente pour les valeurs manquantes.

Selon la colonne, vous pouvez :

- conserver la valeur nulle ;
- remplacer la valeur ;
- exclure la ligne ;
- signaler une donnée incomplète.

Attention

Remplacer systématiquement les valeurs manquantes par zéro n'est pas toujours correct.

Étape 10 – Traiter les doublons

Vérifiez si certaines ventes sont présentes plusieurs fois.

Vous devez :

1. identifier la colonne pertinente ;
2. rechercher les identifiants répétés ;
3. déterminer s'il s'agit de doublons ;
4. supprimer les doublons justifiés.

Question

Pourquoi ne faut-il pas nécessairement supprimer toutes les lignes identiques sans examiner leur signification ?

Étape 11 – Importer les référentiels

Importez le classeur :

`referentiels.xlsx`

Vous devez récupérer les tables :

- Produits ;
- Clients.

Conservez-les sous forme de requêtes distinctes.

Étape 12 – Fusionner avec les produits

Enrichissez la table des ventes à l'aide du référentiel produits.

Vous devez :

1. identifier la clé commune ;
2. sélectionner la jointure adaptée ;
3. effectuer la fusion ;
4. développer les colonnes utiles ;
5. contrôler les résultats.

Question

Quelle jointure permet de conserver toutes les ventes de la table principale ?

Étape 13 – Fusionner avec les clients

Réalisez une seconde fusion avec le référentiel clients.

Votre table doit désormais contenir :

- les informations de vente ;
- les informations produits ;
- les informations clients.

Attention

Vérifiez que les fusions ne multiplient pas anormalement le nombre de lignes.

Étape 14 – Contrôler les correspondances

Certaines ventes peuvent contenir des identifiants absents des référentiels.

Vous devez identifier :

- les produits sans correspondance ;
- les clients sans correspondance ;
- le nombre de lignes concernées.

Question

Que se passe-t-il lorsqu'une jointure gauche ne trouve aucune correspondance ?

Étape 15 – Calculer le montant net

Ajoutez une colonne calculée :

Montant net

La formule à utiliser est :

$$\text{Montant net} = \text{Quantité} \times \text{Prix unitaire} \times (1 - \text{Remise})$$

Consigne

Vérifiez les unités et le format de la colonne Remise avant le calcul.

Étape 16 – Vérifier les montants

Après le calcul :

- vérifiez plusieurs lignes ;
- recherchez les valeurs nulles ;
- recherchez les erreurs ;
- contrôlez les valeurs négatives éventuelles ;
- vérifiez le type numérique.

Important

Une formule correcte peut produire des résultats incorrects si les données d'entrée sont mal interprétées.

Étape 17 – Importer les objectifs

Importez le fichier :

`objectifs_regions_format_large.xlsx`

Les objectifs commerciaux sont organisés par région avec plusieurs colonnes mensuelles.

Question

Cette structure est-elle directement adaptée à une analyse temporelle ?

Étape 18 – Dépivoter les objectifs

Transformez la table pour obtenir une structure de la forme :

Région	Mois	Objectif
Ouest	Janvier	...
Ouest	Février	...
Ouest	Mars	...
Sud	Janvier	...
Sud	Février	...

Consigne

Conservez la région et dépivotez les colonnes correspondant aux mois.

Étape 19 – Vérifier le dépivotage

Après transformation :

Vérifiez que :

- les régions sont conservées ;
- les mois sont dans une seule colonne ;
- les objectifs sont numériques ;
- aucune période n'a été perdue ;
- le nombre de lignes est cohérent.

Question

Pourquoi cette nouvelle structure est-elle plus adaptée aux TCD ?

Étape 20 – Charger les résultats

Chargez dans Excel :

1. la table finale des ventes ;
2. la table des objectifs dépivotés.

Vous pouvez conserver les requêtes intermédiaires uniquement sous forme de connexion.

Objectif

Obtenir deux tables propres et exploitables pour l'analyse.

Étape 21 – Organiser le classeur

Votre classeur doit distinguer :

Élément	**Rôle**
Requêtes sources	Importation des données
Requêtes intermédiaires	Transformations et fusions
Ventes finales	Table commerciale préparée
Objectifs	Table dépivotée

Utilisez des noms explicites pour les requêtes et les feuilles.

Étape 22 – Tester l'actualisation

Vous disposez d'un fichier supplémentaire :

`ventes_2026_07.csv`

Ce fichier contient :

85 ventes

Il servira à tester la reproductibilité du pipeline.

Étape 23 – Ajouter le nouveau mois

Placez le fichier de juillet dans le dossier des ventes mensuelles.

Consigne

N'effectuez aucune opération de copier-coller dans la table finale.

Le nouveau fichier doit être pris en compte par le mécanisme d'importation du dossier.

Étape 24 – Actualiser les requêtes

Dans Excel :

Données

↓

Actualiser tout

Les transformations doivent être réexécutées sur les nouvelles données.

Objectif

Intégrer juillet sans reconstruire le pipeline.

Étape 25 – Contrôler l'actualisation

Avant nettoyage, les sources contiennent :

955 lignes initiales

+

85 lignes supplémentaires

=

1 040 lignes

Attention

Le nombre de lignes finales peut être inférieur si certaines observations sont exclues lors du

Étape 26 – Vérifier le pipeline

Contrôlez les éléments suivants :

- les sept fichiers sont intégrés ;
- les types restent corrects ;
- les anomalies sont traitées ;
- les fusions fonctionnent ;
- les montants sont recalculés ;
- les nouvelles ventes apparaissent ;
- aucune étape manuelle n'a été nécessaire.

Question

Votre pipeline est-il réellement reproductible ?

Étape 27 – Analyser les résultats

À partir des données préparées, répondez aux questions suivantes :

1. Quel est le montant net total des ventes ?
2. Combien de ventes ont été conservées ?
3. Quelle catégorie génère le plus de CA ?
4. Quelle région réalise le plus de ventes ?
5. Quel est le montant net des ventes de juillet ?

Vous pouvez utiliser un TCD pour répondre à ces questions.

Livrable attendu

Votre classeur Excel devra contenir :

- une requête combinant les CSV ;
- des transformations de nettoyage ;
- une fusion avec les produits ;
- une fusion avec les clients ;
- une colonne de montant net ;
- une table d'objectifs dépivotée ;
- les tables finales chargées ;
- un pipeline fonctionnant après actualisation.

Critère principal

Le traitement doit fonctionner avec l'ajout du fichier de juillet.

Checklist finale

Avant de terminer, vérifiez :

- ☐ Les CSV sont combinés.
- ☐ Les types sont corrects.
- ☐ Les anomalies sont traitées.
- ☐ Les doublons sont contrôlés.
- ☐ Les référentiels sont fusionnés.
- ☐ Les montants sont calculés.
- ☐ Les objectifs sont dépivotés.
- ☐ Les résultats sont chargés.
- ☐ Juillet est intégré.
- ☐ Le pipeline s'actualise correctement.

La méthode à retenir

Importer

↓

Combiner

↓

Nettoyer

↓

Enrichir

↓

Transformer

La méthode à retenir

Transformer

↓

Charger

↓

Actualiser

↓

Contrôler

Un pipeline reproductible

De nouvelles données

↓

Une actualisation

↓

Des résultats à jour

À vous de jouer !

2 heures

`seance6_TP_Power_Query_dataset.zip`